

Metaheurystyczne strojenie hiperparametrów CNN

Porównanie GA, PSO, ACO i Harmony Search z wyszukiwaniem losowym i ręcznym na zbiorach FashionMNIST, CIFAR-10 i CIFAR-100

Autorzy: Jakub Grześ, Tomasz Smyda

2026-05-25

Streszczenie. Praca porównuje cztery metaheurystyki – algorytm genetyczny (GA), optymalizację rojem cząstek (PSO), optymalizację kolonią mrówek (ACO) oraz wyszukiwanie harmoniczne (Harmony Search) – z bazowymi metodami doboru hiperparametrów (wyszukiwanie ręczne i losowe) w zadaniu strojenia konwolucyjnej sieci neuronowej. Eksperymenty przeprowadzono na trzech standardowych zbiorach obrazów (FashionMNIST, CIFAR-10, CIFAR-100). Metody automatyczne porównano przy budżecie 20 ewaluacji konfiguracji, gdzie każda ewaluacja obejmowała 10 epok treningu. Manual search potraktowano jako ekspercki punkt odniesienia złożony z 5 ręcznie dobranych konfiguracji. Następnie najlepszą konfigurację każdej metody dotrenowano przez 20 epok.

Wyniki wskazują, że po 20-epokowym dotrenowaniu najlepszą dokładność testową uzyskało manual search na CIFAR-10 (0.8482) i FashionMNIST (0.9383), natomiast GA najlepiej poradził sobie na CIFAR-100 (0.5189). Jednocześnie ręczne strojenie pozostało bardzo silnym punktem odniesienia przy małym budżecie eksperymentalnym, a PSO w przyjętej implementacji uzyskało słabsze wyniki, co sugeruje, że jego klasyczna, ciągła postać może być niedopasowana do mieszanej przestrzeni hiperparametrów zawierającej wiele zmiennych dyskretnych i kategorycznych.

1. Wprowadzenie

Konwolucyjne sieci neuronowe (CNN) są obecnie dominującą rodziną modeli w zadaniach klasyfikacji obrazów. Ich skuteczność silnie zależy od doboru hiperparametrów: tempa uczenia, wielkości batcha, liczby filtrów konwolucyjnych w kolejnych blokach, rozmiaru jądra splotu, prawdopodobieństwa dropoutu, liczby warstw w bloku, a także wyboru optymalizatora oraz regularyzacji.

Klasyczne przeszukiwanie siatkowe szybko staje się w takim problemie niepraktyczne, ponieważ liczba możliwych kombinacji rośnie bardzo szybko wraz z liczbą hiperparametrów. Z tego powodu w literaturze stosuje się metody heurystyczne i metaheurystyczne, które próbują znaleźć dobrą konfigurację bez konieczności sprawdzania całej przestrzeni przeszukiwań [1].

Celem niniejszego raportu jest empiryczne porównanie wybranych metod strojenia hiperparametrów CNN: algorytmu genetycznego (GA), optymalizacji rojem cząstek (PSO), optymalizacji kolonią mrówek (ACO), wyszukiwania harmonicznego (Harmony Search), wyszukiwania losowego oraz ręcznie dobranych konfiguracji referencyjnych. Wszystkie metody automatyczne testowano w tej samej przestrzeni hiperparametrów i przy tym samym budżecie 20 ewaluacji. Manual search potraktowano jako ekspercki punkt odniesienia, a nie jako metodę o identycznym budżecie.

Kluczowe pytania badawcze są następujące:

- Czy którakolwiek z metaheurystyk daje systematyczny zysk jakościowy względem random search / manual search?
- Jak kształtuje się relacja jakości do czasu przeszukiwania (time-to-best)?
- Czy konfiguracja wybrana w fazie szybkiego przeszukiwania (10 epok) przekłada się na jakość po pełniejszym dotrenowaniu (20 epok)?

2. Metodyka

2.1. Przestrzeń przeszukiwań

Eksperyment przeprowadzono w 12-wymiarowej przestrzeni hiperparametrów, obejmującej zarówno parametry architektury CNN, jak i parametry procesu uczenia. Do parametrów architektonicznych należą: liczba bloków konwolucyjnych, liczba filtrów w kolejnych blokach, rozmiar jądra splotu, rozmiar warstwy gęstej oraz użycie batch normalization. Do parametrów treningowych należą: tempo uczenia, wielkość batcha, prawdopodobieństwo dropoutu, optymalizator oraz współczynnik weight decay. Szczegóły przestrzeni zestawiono w tabeli Tabela 1.

Hiperparametr	Typ	Dziedzina
learning_rate	log-float	$[10^{-4}, 10^{-2}]$
batch_size	kategoryczny	{32, 64, 128, 256}
num_blocks	całkowity	{1, 2, 3}
filters_1	kategoryczny	{16, 32, 64}
filters_2	kategoryczny	{32, 64, 128}
filters_3	kategoryczny	{64, 128, 256}
kernel_size	kategoryczny	{3, 5}
dropout	float	$[0.0, 0.5]$
dense_units	kategoryczny	{64, 128, 256}
optimizer	kategoryczny	{adam, sgd, adamw}
weight_decay	log-float	$[10^{-6}, 10^{-3}]$
use_batch_norm	binarny	{0, 1}

Tabela 1: Przestrzeń hiperparametrów użyta w eksperymencie.

Wspólnym modelem bazowym była konfigurowalna sieć TunableCNN. Model składa się z num_blocks bloków konwolucyjnych. Każdy blok zawiera dwie warstwy konwolucyjne, opcjonalną normalizację batchową po każdej konwolucji, aktywację ReLU, operację max pooling oraz dropout. Po części konwolucyjnej następuje spłaszczenie reprezentacji i klasyfikator z jedną ukrytą warstwą gęstą o rozmiarze dense_units.

Ten sam szablon architektury był używany zarówno w fazie krótkiego przeszukiwania, jak i podczas późniejszego dotrenowania najlepszych konfiguracji. Dzięki temu różnice między metodami wynikają z wyboru hiperparametrów, a nie ze zmiany samego modelu.

2.2. Algorytmy przeszukiwania

Zaimplementowano i porównano sześć metod:

- **Manual search** — 5 ręcznie dobranych konfiguracji referencyjnych. Nie jest to metoda o takim samym budżecie jak pozostałe algorytmy, lecz baseline do oceny pozostałych metod.
- **Random search** — 20 niezależnych losowań z przestrzeni hiperparametrów. Metoda ta stanowi prosty punkt odniesienia, pokazujący, ile można osiągnąć bez wykorzystywania informacji z poprzednich ewaluacji.

- **GA** – algorytm genetyczny z populacją 5 osobników przez 4 generacje. Zastosowano selekcję turniejową o rozmiarze 3, krzyżowanie wartości parametrów między rodzicami, mutację z prawdopodobieństwem 0.20 oraz elityzm o rozmiarze 1.
- **PSO** – optymalizacja rojem 5 cząstek przez 4 iteracje. Użyto parametrów $w = 0.7$ oraz $c_1 = c_2 = 1.5$. Ponieważ część hiperparametrów ma charakter kategoriowy lub dyskretny, pozycje cząstek były naprawiane przez ograniczanie wartości do dozwolonych zakresów i zaokrąglanie do najbliższych poprawnych wartości.
- **ACO** – optymalizacja kolonią 5 mrówek przez 4 iteracje. Rozkład feromonów prowadzono osobno dla poszczególnych wymiarów przestrzeni. Po każdej iteracji stosowano parowanie feromonów z parametrem $\rho = 0.2$ oraz wzmacnianie najlepszych konfiguracji.
- **Harmony Search** – metoda z pamięcią harmonii o rozmiarze 5 oraz 15 kolejnymi improwizacjami. Zastosowano parametry $HMCR = 0.9$ oraz $PAR = 0.3$.

Dla metod automatycznych zastosowano jednakowy budżet 20 ewaluacji konfiguracji. W przypadku GA i PSO odpowiada to schematowi 5×4 , dla ACO liczbie 5 mrówek przez 4 iteracje, a dla Harmony Search: 5 konfiguracjom inicjalnym w pamięci harmonii oraz 15 improwizacjom. Manual search ma mniejszy budżet i dlatego jest interpretowany osobno jako punkt odniesienia, a nie jako metoda bezpośrednio równoważna pod względem liczby ewaluacji.

2.3. Procedura ewaluacji

Po zakończeniu przeszukiwania dla każdej pary (zbiór danych, metoda) wybierano konfigurację o najwyższej wartości `val_accuracy`. Następnie wybraną konfigurację trenowano ponownie przez 20 epok, zapisując najlepszy stan modelu względem zbioru walidacyjnego. Dopiero dokładność na zbiorze testowym po tym etapie traktowano jako wynik końcowy danej metody.

Wszystkie eksperymenty uruchamiano z ustalonym ziarnem losowym, aby ograniczyć wpływ losowości na porównanie metod. Należy jednak podkreślić, że pojedyncze ziarno nie wystarcza do oceny istotności statystycznej różnic między metodami; dlatego wyniki należy traktować jako porównanie w jednym kontrolowanym scenariuszu eksperymentalnym.

2.4. Zbiory danych i sprzęt

Eksperymenty przeprowadzono na trzech standardowych benchmarkach klasyfikacji obrazów: **FashionMNIST** [2], **CIFAR-10** [3] oraz **CIFAR-100** [3]. FashionMNIST składa się z obrazów w skali szarości o rozmiarze 28×28 i 10 klas, natomiast CIFAR-10 i CIFAR-100 zawierają kolorowe obrazy RGB o rozmiarze 32×32 . Zbiory CIFAR różnią się liczbą klas: CIFAR-10 obejmuje 10 klas, a CIFAR-100 obejmuje 100 klas.

Raport został przygotowany na podstawie wyników wygenerowanych w notatniku `experiments_full_retraining.ipynb`, a tabele i wykresy zapisano w katalogu `notebooks/results/`. Kod źródłowy implementacji metod przeszukiwania, modelu CNN, procedury ewaluacji oraz skryptów pomocniczych udostępniono w repozytorium projektu [4].


3. Wyniki

3.1. Najlepsza dokładność walidacyjna w fazie przeszukiwania

Tabela 2 oraz rysunek Rysunek 1 podsumowują najlepszą wartość `val_accuracy` osiągniętą przez każdą metodę w fazie przeszukiwania. Każda ewaluacja konfiguracji obejmowała krótki, 10-epokowy trening, dlatego wyniki z tej części należy interpretować jako miarę jakości konfiguracji w warunkach ograniczonego budżetu treningowego.

Metoda	CIFAR-10	CIFAR-100	FashionMNIST
ACO	0.7922	0.3652	0.9262
GA	0.8178	0.4432	0.9322
Harmony Search	0.7740	0.4034	0.9342
Manual search	0.7980	0.4288	0.9365
PSO	0.7984	0.3138	0.9197
Random search	0.8166	0.4094	0.9328

Tabela 2: Najlepsza val_accuracy uzyskana w fazie przeszukiwania (10 epok / ewaluację).




Rysunek 1: Najlepsza val_accuracy per metoda na każdym zbiorze w fazie przeszukiwania.


Na zbiorze CIFAR-10 najwyższą dokładność walidacyjną uzyskał GA (0.8178), bardzo nieznacznie wyprzedzając random search (0.8166) i manual search (0.7980). Na zbiorze CIFAR-100 ponownie najlepszy był GA (0.4432), a kolejne miejsca zajęły manual search (0.4288) i random search (0.4094). Na FashionMNIST najwyższą val_accuracy osiągnęło manual search (0.9365), przy czym Harmony Search, random search i GA również uplasowały się bardzo blisko siebie w zakresie 0.932–0.934. Sugeruje to, że dla tego zbioru badana architektura stosunkowo łatwo osiąga wysoki poziom jakości, a wybór metody strojenia ma mniejsze znaczenie niż w przypadku trudniejszych zbiorów CIFAR.

3.2. Krzywe best-so-far


Wykresy Rysunek 2, Rysunek 3 i Rysunek 4 pokazują przebieg najlepszej dotychczas znalezionej wartości val_accuracy w funkcji numeru ewaluacji. Taka prezentacja pozwala ocenić nie tylko końcową jakość, ale również tempo znajdowania dobrych konfiguracji.



Rysunek 2: Best-so-far val_accuracy na CIFAR-10. GA i ACO wyraźnie przewyższają pozostałe metody po ok. 10 ewaluacjach.



Rysunek 3: Best-so-far val_accuracy na CIFAR-100. ACO osiąga maksimum już w 3. ewaluacji; GA dogania w końcowej fazie.




Rysunek 4: Best-so-far val_accuracy na FashionMNIST. Wszystkie metody zbiegają do zbliżonego poziomu.

Na CIFAR-10 random search i manual search szybko osiągają poziom zbliżony do końcowego optimum, ale GA ostatecznie uzyskuje minimalnie lepszy wynik. Na CIFAR-100 GA poprawia się najbardziej w końcowych ewaluacjach i wyraźnie wyprzedza pozostałe metody. Na FashionMNIST wszystkie metody dochodzą do bardzo podobnego poziomu. PSO uzyskało słabszy przebieg best-so-far. Może to wynikać z faktu, że klasyczna reprezentacja PSO operuje na pozycjach ciągłych, podczas gdy badana przestrzeń zawiera wiele zmiennych dyskretnych i kategorycznych, które następnie muszą być naprawiane do najbliższych dozwolonych wartości.

3.3. Czas do osiągnięcia najlepszego wyniku

Maksymalna wartość val_accuracy nie opisuje w pełni zachowania metody. Istotne jest również to, jak szybko dana metoda znajduje swoją najlepszą konfigurację.

Rysunek 5 pokazuje czas potrzebny do osiągnięcia najlepszej wartości val_accuracy przez każdą metodę na trzech analizowanych zbiorach danych.



Rysunek 5: Czas do osiągnięcia najlepszej val_accuracy dla każdej metody i zbioru danych.


Warto interpretować tę metrykę razem z maksymalną osiągniętą dokładnością walidacyjną. Krótki czas do najlepszego wyniku nie musi oznaczać, że dana metoda znalazła najlepszą konfigurację globalnie – może jedynie oznaczać, że szybko osiągnęła swój własny najlepszy wynik w ramach danego

uruchomienia. Na CIFAR-10 manual search osiąga najlepszy wynik po 4 ewaluacjach, random search po 7, a GA dopiero po 18. Na CIFAR-100 manual search także znajduje najlepszą konfigurację bardzo wcześnie, podczas gdy GA potrzebuje znacznie większej części budżetu. Na FashionMNIST najszybsze są manual search i PSO, ale najlepszy wynik nadal należy do manual search. Dla tej metryki wynik random jest zupełnie nieprzewidywalny, ponieważ nie ma mechanizmu uczenia się z wcześniejszych ewaluacji.

3.4. Analiza zależności hiperparametrów i metryk

Dla każdej pary (zbiór danych, metoda) obliczono macierze korelacji Pearsona między hiperparametrami a metrykami uzyskanymi w fazie przeszukiwania: `val_accuracy`, `test_accuracy`, `time_sec` oraz `num_params`. Analiza ta ma charakter eksploracyjny i służy wskazaniu potencjalnych zależności w wynikach eksperymentu. Nie należy jej interpretować jako formalnego dowodu wpływu pojedynczych hiperparametrów na jakość modelu, ponieważ liczba ocenionych konfiguracji jest ograniczona, a próbki generowane przez metaheurystyki nie są niezależnym losowaniem z całej przestrzeni.

Ze względu na objętość raportu w głównej części przedstawiono jedną reprezentatywną mapę korelacji — dla metody GA na zbiorze CIFAR-10. Pełny zestaw map korelacji znajduje się w katalogu `report/figures/hyperparam_correlations_*` repozytorium projektu [4].



Rysunek 6: Korelacje hiperparametrów z metrykami dla GA na zbiorze CIFAR-10.

W przedstawionym przykładzie zależności między hiperparametrami a jakością modelu są umiarkowane. Najsilniejszy dodatni związek z `val_accuracy` ma liczba filtrów w pierwszym bloku (`filters_1`, około 0.22), natomiast liczba bloków i rozmiar batcha wykazują umiarkowanie ujemną korelację z jakością. Pozostałe korelacje z dokładnością walidacyjną są słabsze, co sugeruje, że w tej próbie jakość modelu nie była kontrolowana przez pojedynczy hiperparametr, lecz przez kombinację kilku ustawień.


3.5. Jakość końcowa po dotrenowaniu

W fazie przeszukiwania każda konfiguracja była oceniana po krótkim, 10-epokowym treningu. Taka procedura pozwala ograniczyć koszt eksperymentu, ale nie daje jeszcze pełnej informacji o jakości konfiguracji po dłuższym uczeniu. Dlatego dla każdej pary (zbiór danych, metoda) wybrano konfigurację o najwyższej wartości `val_accuracy` w fazie przeszukiwania, a następnie dotrenowano ją przez 20 epok. Wynik testowy uzyskany po tym etapie traktujemy jako końcową ocenę danej metody.

Tabela 3 oraz rysunek Rysunek 7 przedstawiają końcową wartość `test_accuracy` po 20-epokowym dotrenowaniu najlepszej konfiguracji każdej metody.

Metoda	CIFAR-10	CIFAR-100	FashionMNIST
ACO	0.8109	0.4308	0.9202
GA	0.8406	0.5189	0.9331
Harmony Search	0.8161	0.4680	0.9305
Manual search	0.8482	0.4666	0.9383
PSO	0.7373	0.3720	0.9180
Random search	0.8449	0.4680	0.9313

Tabela 3: Końcowa test_accuracy po 20-epokowym dotrenowaniu najlepszej konfiguracji.




Rysunek 7: Końcowa test_accuracy po retrainingu — metoda × zbiór.

W przeprowadzonym eksperymencie manual search uzyskał najwyższą końcową test_accuracy na CIFAR-10 (0.8482) i FashionMNIST (0.9383), natomiast GA zwyciężył na CIFAR-100 (0.5189). Na CIFAR-10 random search był bardzo blisko GA (0.8449 wobec 0.8406), a manual search wyprzedził pozostałe metody o około 0.3–0.8 p.p. Na CIFAR-100 GA uzyskał wynik o około 5.2 p.p. wyższy od manual search, około 8.8 p.p. wyższy od ACO oraz około 5.1 p.p. wyższy od random search.

Manual search pozostaje jednak silną linią bazową. Na CIFAR-10 osiąga drugi wynik po random search i przed ACO, natomiast na CIFAR-100 jest drugą najlepszą metodą. Wskazuje to, że przy małym budżecie ewaluacji ręcznie dobrane konfiguracje mogą być konkurencyjne wobec metod automatycznych, zwłaszcza jeśli zostały dobrane na podstawie intuicji dotyczącej architektury CNN.

Krzywe dotrenowania na rysunku Rysunek 8 pozwalają ocenić, czy konfiguracje wybrane po krótkim treningu zachowują przewagę również w dłuższym uczeniu. W badanym ustawieniu ranking metod po dotrenowaniu jest tylko częściowo zgodny z wynikami fazy przeszukiwania. GA utrzymuje przewagę na CIFAR-100, natomiast na CIFAR-10 i FashionMNIST najlepsze końcowe wyniki osiąga manual search. Oznacza to, że 10-epokowa ewaluacja była użytecznym, choć przybliżonym, kryterium wyboru konfiguracji do dalszego treningu.



Rysunek 8: Krzywe val_accuracy w trakcie 20-epokowego dotrenowania.

3.6. Zmienność jakości ocenianych konfiguracji

Dotychczasowe zestawienia koncentrowały się głównie na najlepszych konfiguracjach znalezionych przez poszczególne metody. Dodatkowo przeanalizowano rozkład jakości wszystkich konfiguracji ocenionych w fazie przeszukiwania. Tabela 4 pokazuje średnią oraz odchylenie standardowe `val_accuracy` i `test_accuracy` dla każdej metody na trzech zbiorach danych.

Wartości odchylenia standardowego nie opisują tutaj powtarzalności metod między niezależnymi uruchomieniami. Pokazują jedynie, jak bardzo różniły się wyniki konfiguracji ocenionych w ramach jednego przebiegu eksperymentu.

Metoda	C10 val	C10 test	C100 val	C100 test	FMNIST val	FMNIST test
ACO	0.612 ± 0.171	0.611 ± 0.169	0.234 ± 0.115	0.233 ± 0.117	0.859 ± 0.180	0.853 ± 0.180
GA	0.711 ± 0.107	0.711 ± 0.105	0.320 ± 0.129	0.321 ± 0.131	0.923 ± 0.012	0.918 ± 0.012
Harmony S.	0.537 ± 0.207	0.536 ± 0.208	0.200 ± 0.106	0.197 ± 0.107	0.867 ± 0.182	0.862 ± 0.181
Manual	0.761 ± 0.045	0.758 ± 0.043	0.325 ± 0.096	0.323 ± 0.102	0.932 ± 0.003	0.925 ± 0.002
PSO	0.375 ± 0.276	0.373 ± 0.278	0.065 ± 0.084	0.064 ± 0.083	0.851 ± 0.190	0.846 ± 0.189
Random	0.604 ± 0.199	0.603 ± 0.199	0.220 ± 0.123	0.221 ± 0.125	0.907 ± 0.029	0.902 ± 0.029

Tabela 4: Średnia i odchylenie standardowe jakości konfiguracji ocenionych w fazie przeszukiwania.

Skróty: C10 – CIFAR-10, C100 – CIFAR-100, FMNIST – FashionMNIST.

Na CIFAR-10 najwyższą średnią jakość ocenianych konfiguracji uzyskał manual search, przy jednocześnie bardzo małym rozrzucie wyników. Podobny obraz widać na CIFAR-100, gdzie manual search ma najwyższe średnie `val_accuracy` i `test_accuracy`, natomiast PSO osiąga wyraźnie niższą średnią i duży względny rozrzut. Sugeruje to, że w tym eksperymencie ręcznie dobrane konfiguracje były szczególnie stabilną linią bazową, natomiast PSO często odwiedzało słabe konfiguracje.

Na FashionMNIST różnice między metodami są mniejsze, ponieważ większość konfiguracji osiąga stosunkowo wysoką jakość. Najniższy rozrzut ma manual search, co wynika z faktu, że składa się z kilku ręcznie dobranych, sensownych konfiguracji bazowych. Nie należy jednak interpretować tego jako dowodu ogólnej stabilności manual search, ponieważ metoda ta nie eksploruje przestrzeni w taki sam sposób jak algorytmy automatyczne.

3.7. Najlepsze konfiguracje

Tabela 5 zestawia najlepsze konfiguracje znalezione przez poszczególne metody na trzech zbiorach danych. Za najlepszą konfigurację uznano tę, która w fazie przeszukiwania uzyskała najwyższą wartość `val_accuracy` dla danej pary (zbiór danych, metoda). W tabeli pokazano najważniejsze hiperparametry wpływające na architekturę i trening; pełne konfiguracje, obejmujące wszystkie parametry z przestrzeni przeszukiwań, udostępniono w repozytorium projektu jako pliki `best_configs_*.csv` [4].

Zbiór	Metoda	val	test	lr	bs	blocks	dropout	dense
CIFAR-10	ACO	0.7922	0.7899	1.0×10^{-3}	64	3	0.10	64
CIFAR-10	GA	0.8178	0.8095	1.56×10^{-4}	64	3	0.27	128
CIFAR-10	Manual	0.7980	0.7947	2.0×10^{-4}	128	3	0.40	256
CIFAR-10	PSO	0.7984	0.7834	1.0×10^{-2}	128	2	0.34	256
CIFAR-10	HS	0.7740	0.7775	1.56×10^{-4}	128	3	0.27	128
CIFAR-10	Random	0.8166	0.8079	8.40×10^{-4}	128	3	0.42	64
CIFAR-100	GA	0.4432	0.4501	1.56×10^{-4}	64	3	0.27	128
CIFAR-100	Manual	0.4288	0.4328	5.0×10^{-4}	128	2	0.30	256
CIFAR-100	Random	0.4094	0.4147	1.56×10^{-4}	128	3	0.27	128
CIFAR-100	HS	0.4034	0.4123	1.56×10^{-4}	128	3	0.27	128
CIFAR-100	ACO	0.3652	0.3732	1.0×10^{-4}	64	3	0.10	64
CIFAR-100	PSO	0.3138	0.3075	1.40×10^{-3}	32	2	0.09	128
FashionMNIST	Manual	0.9365	0.9251	2.0×10^{-4}	128	3	0.40	256
FashionMNIST	HS	0.9342	0.9280	1.43×10^{-3}	32	3	0.03	256
FashionMNIST	Random	0.9328	0.9303	6.34×10^{-4}	32	1	0.33	128
FashionMNIST	GA	0.9322	0.9276	1.52×10^{-3}	256	3	0.28	256
FashionMNIST	ACO	0.9262	0.9183	1.0×10^{-2}	128	3	0.25	256
FashionMNIST	PSO	0.9197	0.9152	1.0×10^{-2}	256	1	0.47	256

Tabela 5: Najlepsze konfiguracje znalezione przez metody na trzech zbiorach danych.

Warto zauważyć, że najlepsze konfiguracje nie tworzą jednego uniwersalnego wzorca dla wszystkich zbiorów. Dla CIFAR-10 i CIFAR-100 korzystne okazały się konfiguracje z umiarkowaną liczbą bloków i niskim albo średnim dropoutem, natomiast na FashionMNIST manual search i Harmony Search wykorzystwały bardziej pojemne układy z większą liczbą filtrów i wyższym dropoutem. Oznacza to, że skuteczność konfiguracji jest zależna zarówno od zbioru danych, jak i od sposobu eksploracji przestrzeni przez daną metodę.

4. Dyskusja i wnioski

W przeprowadzonym eksperymencie liderzy różnili się między zbiorami danych: GA uzyskał najwyższą końcową test_accuracy na CIFAR-100, natomiast manual search zwyciężył na CIFAR-10 i FashionMNIST. Wynik ten sugeruje, że w badanej przestrzeni hiperparametrów mechanizmy selekcji, elityzmu i mutacji mogą dobrze kierować populację, ale ich skuteczność zależy od charakterystyki zbioru i budżetu ewaluacji. Nie należy traktować tego jako bezwarunkowej przewagi GA nad pozostałymi metodami, ponieważ eksperyment wykonano przy ograniczonym budżecie ewaluacji i dla pojedynczego ziarna losowego.

Istotnym wynikiem jest również bardzo dobra pozycja manual search. Ręcznie dobrane konfiguracje okazały się szczególnie konkurencyjne na CIFAR-10 i FashionMNIST, gdzie po dotrenowaniu uzyskały najlepsze wyniki. Na CIFAR-100 manual search pozostał drugą najlepszą metodą po GA. Pokazuje to, że przy małym budżecie kilka sensownie dobranych konfiguracji eksperckich może być trudną do pobicia linią bazową.

PSO uzyskało słabsze wyniki niż GA, ACO i często również random search. Możliwym wyjaśnieniem jest niedopasowanie klasycznej, ciągłej reprezentacji PSO do mieszanej przestrzeni hiperparametrów, w której wiele wymiarów ma charakter dyskretny lub kategoriowy. Wartości cząstek musiały być naprawiane przez zaokrąglanie lub mapowanie do najbliższych dopuszczalnych wartości, co mogło ograniczać użyteczność mechanizmu prędkości.

Harmony Search osiągał wyniki pośrednie. Metoda była lepsza od PSO w części eksperymentów, ale na trudniejszych zbiorach CIFAR ustępowała GA i ACO. Jedną z możliwych przyczyn jest wysoka wartość parametru HMCR, która sprzyja wybieraniu wartości z pamięci harmonii. Przy małej pamięci i ograniczonym budżecie może to prowadzić do zbyt szybkiej eksploatacji wcześniej znalezionych konfiguracji kosztem dalszej eksploracji.

Wyniki po 20-epokowym dotrenowaniu wskazują, że krótka, 10-epokowa ewaluacja była użytecznym kryterium wyboru konfiguracji do dalszego treningu, ale nie przesądzała o ostatecznym rankingu

metod. W części przypadków lepszy wynik po retreningu miały konfiguracje, które nie były absolutnie najlepsze w fazie przeszukiwania. Nie oznacza to jednak, że `val_accuracy` po 10 epokach jest pełnym substytutem dłuższego treningu. Jest to raczej kosztowo tańszy wskaźnik jakości konfiguracji.

Analiza korelacji hiperparametrów z metrykami miała charakter pomocniczy. Najłatwiej interpretowalne były zależności związane z kosztem modelu, np. dodatnia korelacja liczby bloków z czasem treningu. Zależności między pojedynczymi hiperparametrami a jakością były słabsze i zależne od metody oraz zbioru danych.

4.1. Ograniczenia i możliwe dalsze analizy

Najważniejszym ograniczeniem eksperymentu jest użycie pojedynczego ziarna losowego. Wyniki metod stochastycznych mogą zależeć od inicjalizacji populacji, losowania konfiguracji, podziału train/validation oraz inicjalizacji wag sieci. Silniejsze wnioski wymagałyby powtórzenia eksperymentów dla kilku seedów i raportowania średnich oraz odchyłeń standardowych wyników końcowych.

Drugim ograniczeniem jest mały budżet przeszukiwania. Dwadzieścia ewaluacji to realistyczny, ale bardzo ograniczony budżet dla 12-wymiarowej przestrzeni hiperparametrów. W dalszych eksperymentach warto porównać metody także dla większych budżetów, np. 40 lub 60 ewaluacji, oraz analizować krzywe best-so-far jako funkcję liczby ewaluacji.

Bibliografia

- [1] Q. S. Hamad, H. Samma, i S. A. Suandi, „Optimization of Convolutional Neural Network Hyperparameter for Medical Image Diagnosis using Metaheuristic Algorithms: A short Recent Review (2019-2022)”. [Online]. Dostępne na: <https://arxiv.org/abs/2412.17956>
- [2] H. Xiao, K. Rasul, i R. Vollgraf, „Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms”.
- [3] A. Krizhevsky, V. Nair, i G. Hinton, „Learning multiple layers of features from tiny images”, technical report, 2009. [Online]. Dostępne na: <https://www.cs.toronto.edu/~kriz/cifar.html>
- [4] J. Grześ i T. Smyda, „cnn-metaheuristics: Metaheuristic Hyperparameter Tuning for CNNs”. [Online]. Dostępne na: <https://github.com/tsmyda/cnn-metaheuristics>