

Metaheurystyczne strojenie hiperparametrów CNN

Porównanie GA, PSO, ACO i Harmony Search z wyszukiwaniem losowym i ręcznym na zbiorach FashionMNIST, CIFAR-10 i CIFAR-100

Autorzy: Jakub Grześ, Tomasz Smyda

2026-06-01

Streszczenie. Praca porównuje cztery metaheurystyki - algorytm genetyczny (GA), optymalizację rojem cząstek (PSO), optymalizację kolonią mrówek (ACO) oraz wyszukiwanie harmoniczne (Harmony Search) z bazowymi metodami doboru hiperparametrów (wyszukiwanie ręczne i losowe) w zadaniu strojenia konwolucyjnej sieci neuronowej. Eksperymenty przeprowadzono na trzech zbiorach obrazów (FashionMNIST, CIFAR-10, CIFAR-100). Metody automatyczne porównano przy budżecie 50 ewaluacji konfiguracji, gdzie każda ewaluacja obejmowała 10 epok treningu. Manual search potraktowano jako ekspercki punkt odniesienia złożony z 5 ręcznie dobranych konfiguracji. Następnie najlepszą konfigurację każdej metody dotrenowano przez 20 epok.

Wyniki wskazują, że po 20-epokowym dotrenowaniu najwyższą dokładność testową uzyskał random search na CIFAR-10 (0.8526), manual search na FashionMNIST (0.9383), natomiast GA najlepiej poradził sobie na CIFAR-100 (0.5587). PSO w przyjętej implementacji było jedną ze słabszych metod, szczególnie na CIFAR-10 i FashionMNIST, co sugeruje, że jego klasyczna, ciągła postać może być niedopasowana do mieszanej przestrzeni hiperparametrów zawierającej wiele zmiennych dyskretnych i kategorycznych.

Spis treści

1. Wprowadzenie	2
2. Metodyka	3
2.1. Przestrzeń przeszukiwań	3
2.2. Algorytmy przeszukiwania	3
2.3. Procedura ewaluacji	4
2.4. Zbiory danych i sprzęt	4
3. Wyniki	4
3.1. Najlepsza dokładność walidacyjna w fazie przeszukiwania	4
3.2. Krzywe best-so-far	5
3.3. Czas do osiągnięcia najlepszego wyniku	7
3.4. Analiza zależności hiperparametrów i metryk	8
3.5. Jakość końcowa po dotrenowaniu	8
3.6. Zmienność jakości ocenianych konfiguracji	10
3.7. Najlepsze konfiguracje	10
4. Dyskusja i wnioski	11
4.1. Ograniczenia i możliwe dalsze analizy	12
Bibliografia	12

1. Wprowadzenie

Konwolucyjne sieci neuronowe (CNN) są obecnie dominującą rodziną modeli w zadaniach klasyfikacji obrazów. Ich skuteczność silnie zależy od doboru hiperparametrów: tempa uczenia, wielkości batcha, liczby filtrów konwolucyjnych w kolejnych blokach, rozmiaru jądra splotu, prawdopodobieństwa dropoutu, liczby warstw w bloku, a także wyboru optymalizatora oraz regularyzacji.

Klasyczne przeszukiwanie siatkowe szybko staje się w takim problemie niepraktyczne, ponieważ liczba możliwych kombinacji rośnie bardzo szybko wraz z liczbą hiperparametrów. Z tego powodu w literaturze stosuje się metody heurystyczne i metaheurystyczne, które próbują znaleźć dobrą konfigurację bez konieczności sprawdzania całej przestrzeni przeszukiwań [1].

Celem niniejszego raportu jest empiryczne porównanie wybranych metod strojenia hiperparametrów CNN: algorytmu genetycznego (GA), optymalizacji rojem cząstek (PSO), optymalizacji kolonią mrówek (ACO), wyszukiwania harmonicznego (Harmony Search), wyszukiwania losowego oraz ręcznie dobranych konfiguracji referencyjnych. Wszystkie metody automatyczne testowano w tej samej przestrzeni hiperparametrów i przy tym samym budżecie 50 ewaluacji. Manual search potraktowano jako ekspercki punkt odniesienia, a nie jako metodę o identycznym budżecie.

Kluczowe pytania badawcze są następujące:

- Czy którakolwiek z metaheurystyk daje systematyczny zysk jakościowy względem random search / manual search?
- Jak kształtuje się relacja jakości do czasu przeszukiwania (time-to-best)?
- Czy konfiguracja wybrana w fazie szybkiego przeszukiwania przekłada się na jakość po pełniejszym dotrenowaniu?

2. Metodyka

2.1. Przestrzeń przeszukiwań

Eksperyment przeprowadzono w 12-wymiarowej przestrzeni hiperparametrów, obejmującej zarówno parametry architektury CNN, jak i parametry procesu uczenia. Do parametrów architektonicznych należą: liczba bloków konwolucyjnych, liczba filtrów w kolejnych blokach, rozmiar jądra splotu, rozmiar warstwy gęstej oraz użycie batch normalization. Do parametrów treningowych należą: tempo uczenia, wielkość batcha, prawdopodobieństwo dropoutu, optymalizator oraz współczynnik weight decay. Szczegóły przestrzeni zestawiono w tabeli Tabela 1.

Hiperparametr	Typ	Dziedzina
learning_rate	log-float	$[10^{-4}, 10^{-2}]$
batch_size	kategoryczny	{32, 64, 128, 256}
num_blocks	całkowity	{1, 2, 3}
filters_1	kategoryczny	{16, 32, 64}
filters_2	kategoryczny	{32, 64, 128}
filters_3	kategoryczny	{64, 128, 256}
kernel_size	kategoryczny	{3, 5}
dropout	float	[0.0, 0.5]
dense_units	kategoryczny	{64, 128, 256}
optimizer	kategoryczny	{adam, sgd, adamw}
weight_decay	log-float	$[10^{-6}, 10^{-3}]$
use_batch_norm	binarny	{0, 1}

Tabela 1: Przestrzeń hiperparametrów użyta w eksperymencie.

Wspólnym modelem bazowym była konfigurowalna sieć TunableCNN. Model składa się z num_blocks bloków konwolucyjnych. Każdy blok zawiera dwie warstwy konwolucyjne, opcjonalną normalizację batchową po każdej konwolucji, aktywację ReLU, operację max pooling oraz dropout. Po części konwolucyjnej następuje spłaszczenie reprezentacji i klasyfikator z jedną ukrytą warstwą gęstą o rozmiarze dense_units.

Ten sam szablon architektury był używany zarówno w fazie krótkiego przeszukiwania, jak i podczas późniejszego dotrenowania najlepszych konfiguracji. Dzięki temu różnice między metodami wynikają z wyboru hiperparametrów, a nie ze zmiany samego modelu.

2.2. Algorytmy przeszukiwania

Zaimplementowano i porównano sześć metod:

- **Manual search** — 5 ręcznie dobranych konfiguracji referencyjnych. Nie jest to metoda o takim samym budżecie jak pozostałe algorytmy, lecz baseline do oceny pozostałych metod.
- **Random search** — 50 niezależnych losowań z przestrzeni hiperparametrów. Metoda ta stanowi prosty punkt odniesienia, pokazujący, ile można osiągnąć bez wykorzystywania informacji z poprzednich ewaluacji.

- **GA** – algorytm genetyczny z populacją 5 osobników przez 10 generacji. Zastosowano selekcję turniejową o rozmiarze 3, krzyżowanie wartości parametrów między rodzicami, mutację z prawdopodobieństwem 0.20 oraz elityzm o rozmiarze 1.
- **PSO** – optymalizacja rojem 5 cząstek przez 10 iteracji. Użyto parametrów $w = 0.7$ oraz $c_1 = c_2 = 1.5$. Ponieważ część hiperparametrów ma charakter kategoriowy lub dyskretny, pozycje cząstek były naprawiane przez ograniczanie wartości do dozwolonych zakresów i zaokrąglanie do najbliższych poprawnych wartości.
- **ACO** – optymalizacja kolonią 5 mrówek przez 10 iteracji. Rozkład feromonów prowadzono osobno dla poszczególnych wymiarów przestrzeni. Po każdej iteracji stosowano parowanie feromonów z parametrem $\rho = 0.2$ oraz wzmacnianie najlepszych konfiguracji.
- **Harmony Search** – metoda z pamięcią harmonii o rozmiarze 5 oraz 45 kolejnymi improwizacjami. Zastosowano parametry HMCR = 0.9 oraz PAR = 0.3.

Dla metod automatycznych zastosowano jednakowy budżet 50 ewaluacji konfiguracji. W przypadku GA i PSO odpowiada to schematowi 5×10 , dla ACO liczbie 5 mrówek przez 10 iteracji, a dla Harmony Search: 5 konfiguracjom inicjalnym w pamięci harmonii oraz 45 improwizacjom.

2.3. Procedura ewaluacji

Po zakończeniu przeszukiwania dla każdej pary (zbiór danych, metoda) wybierano konfigurację o najwyższej wartości `val_accuracy`. Następnie wybraną konfigurację trenowano ponownie przez 20 epok, zapisując najlepszy stan modelu względem zbioru walidacyjnego. Dopiero dokładność na zbiorze testowym po tym etapie traktowano jako wynik końcowy danej metody.

Wszystkie eksperymenty uruchamiano z ustalonym ziarnem losowym, aby ograniczyć wpływ losowości na porównanie metod. Należy jednak podkreślić, że pojedyncze ziarno nie wystarcza do oceny istotności statystycznej różnic między metodami, ale musieliśmy ograniczyć liczbę uruchomień ze względu na koszty obliczeniowe.

2.4. Zbiory danych i sprzęt

Ekspertymenty przeprowadzono na trzech standardowych benchmarkach klasyfikacji obrazów: FashionMNIST [2], CIFAR-10 [3] oraz CIFAR-100 [3]. FashionMNIST składa się z obrazów w skali szarości o rozmiarze 28×28 i 10 klas, natomiast CIFAR-10 i CIFAR-100 zawierają kolorowe obrazy RGB o rozmiarze 32×32 . Zbiory CIFAR różnią się liczbą klas: CIFAR-10 obejmuje 10 klas, a CIFAR-100 obejmuje 100 klas.

Raport został przygotowany na podstawie wyników wygenerowanych w notatniku `experiments_full_retraining.ipynb`, a tabele i wykresy zapisano w katalogu `report/results/`. Kod źródłowy implementacji udostępniono w repozytorium projektu [4].

3. Wyniki


Wszystkie obliczenia przeprowadzono na maszynie z procesorem Intel Core i7-11800H, 16 GB RAM oraz kartą graficzną NVIDIA GeForce RTX 3070.

3.1. Najlepsza dokładność walidacyjna w fazie przeszukiwania

Tabela 2 oraz rysunek Rysunek 1 podsumowują najlepszą wartość `val_accuracy` osiągniętą przez każdą metodę w fazie przeszukiwania. Każda ewaluacja konfiguracji obejmowała krótki, 10-epokowy trening, dlatego wyniki z tej części należy interpretować jako miarę jakości konfiguracji w warunkach ograniczonego budżetu treningowego.

Metoda	CIFAR-10	CIFAR-100	FashionMNIST
ACO	0.8140	0.4880	0.9383
GA	0.8284	0.5022	0.9390
Harmony Search	0.8296	0.4656	0.9383
Manual search	0.7980	0.4288	0.9365
PSO	0.7984	0.4816	0.9198
Random search	0.8168	0.4990	0.9388

Tabela 2: Najlepsza val_accuracy uzyskana w fazie przeszukiwania (10 epok / ewaluację).




Rysunek 1: Najlepsza val_accuracy per metoda na każdym zbiorze w fazie przeszukiwania.


Na zbiorze CIFAR-10 najwyższą dokładność walidacyjną uzyskał Harmony Search (0.8296), bardzo nieznacznie wyprzedzając GA (0.8284) i random search (0.8168). Na zbiorze CIFAR-100 najlepszy był GA (0.5022), a kolejne miejsca zajęły random search (0.4990) i ACO (0.4880). Na FashionMNIST najwyższą val_accuracy osiągnęło GA (0.9390), przy czym pozostałe metody uplasowały się bardzo blisko siebie. Sugeruje to, że dla tego zbioru badana architektura stosunkowo łatwo osiąga wysoki poziom jakości, a wybór metody strojenia ma mniejsze znaczenie niż w przypadku trudniejszych zbiorów CIFAR.

3.2. Krzywe best-so-far


Wykresy Rysunek 2, Rysunek 3 i Rysunek 4 pokazują przebieg najlepszej dotychczas znalezionej wartości val_accuracy w funkcji numeru ewaluacji. Taka prezentacja pozwala ocenić nie tylko końcową jakość, ale również tempo znajdowania dobrych konfiguracji.



Rysunek 2: Best-so-far val_accuracy na CIFAR-10.



Rysunek 3: Best-so-far val_accuracy na CIFAR-100.




Rysunek 4: Best-so-far val_accuracy na FashionMNIST.

Na CIFAR-10 kilka metod szybko osiąga poziom zbliżony do końcowego optimum, ale końcowe różnice pozostają niewielkie. Na CIFAR-100 Harmony Search poprawia się w końcowych ewaluacjach, ale nie wyprzedza najlepszych metod. Najwyższą końcową val_accuracy w fazie przeszukiwania uzyskał GA. Na FashionMNIST wszystkie metody dochodzą do bardzo podobnego poziomu, z wyjątkiem PSO. Może to wynikać z faktu, że klasyczna reprezentacja PSO operuje na pozycjach ciągłych, podczas gdy badana przestrzeń zawiera wiele zmiennych dyskretnych i kategorycznych, które następnie muszą być naprawiane do najbliższych dozwolonych wartości, obniżając swobodę algorytmu.

3.3. Czas do osiągnięcia najlepszego wyniku

Maksymalna wartość val_accuracy nie opisuje w pełni zachowania metody. Istotne jest również to, jak szybko dana metoda znajduje swoją najlepszą konfigurację.

Rysunek 5 pokazuje czas potrzebny do osiągnięcia najlepszej wartości val_accuracy przez każdą metodę na trzech analizowanych zbiorach danych.



Rysunek 5: Czas do osiągnięcia najlepszej val_accuracy dla każdej metody i zbioru danych.


Warto interpretować tę metrykę razem z maksymalną osiągniętą dokładnością walidacyjną. Krótki czas do najlepszego wyniku nie musi oznaczać, że dana metoda znalazła najlepszą konfigurację globalnie - może jedynie oznaczać, że szybko osiągnęła swój własny najlepszy wynik w ramach danego uruchomienia.

Należy też podkreślić nieprzewidywalność wyniku dla Random Search, który może znaleźć dobrą konfigurację już w pierwszych próbach lub dopiero w ostatnich, co jest charakterystyczne dla metody opartej na losowym próbkowaniu.

3.4. Analiza zależności hiperparametrów i metryk

Dla każdej pary (zbiór danych, metoda) obliczono macierze korelacji Pearsona między hiperparametrami a metrykami uzyskanymi w fazie przeszukiwania: `val_accuracy`, `test_accuracy`, `time_sec` oraz `num_params`. Analiza ta ma charakter eksploracyjny i służy wskazaniu potencjalnych zależności w wynikach eksperymentu. Nie należy jej interpretować jako formalnego dowodu wpływu pojedynczych hiperparametrów na jakość modelu, ponieważ liczba ocenionych konfiguracji jest ograniczona, a próbki generowane przez metaheurystyki nie są niezależnym losowaniem z całej przestrzeni.

Ze względu na objętość raportu w głównej części przedstawiono jedną reprezentatywną mapę korelacji - dla metody GA na zbiorze CIFAR-10. Pełny zestaw map korelacji znajduje się w katalogu `report/figures/hyperparam_correlations_*` repozytorium projektu [4].



Rysunek 6: Korelacje hiperparametrów z metrykami dla GA na zbiorze CIFAR-10.

W przedstawionym przykładzie zależności między hiperparametrami a jakością modelu są umiarkowane. Najsilniejszy dodatni związek z `val_accuracy` ma liczba filtrów w pierwszym bloku (`filters_1`, około 0.50), a następnie liczba bloków (≈ 0.35) i rozmiar jądra splotu (≈ 0.25). Rozmiar batcha oraz learning rate są umiarkowanie ujemnie skorelowane z jakością, a pozostałe zależności są słabsze. Najmocniejsza zależność z liczbą parametrów dotyczy `filters_3` (≈ 0.87), co jest zgodne z tym, że w tej architekturze to ostatni blok najmocniej determinuje rozmiar modelu.


3.5. Jakość końcowa po dotrenowaniu

W fazie przeszukiwania każda konfiguracja była oceniana po krótkim, 10-epokowym treningu. Taka procedura pozwala ograniczyć koszt eksperymentu, ale nie daje jeszcze pełnej informacji o jakości konfiguracji po dłuższym uczeniu. Dlatego dla każdej pary (zbiór danych, metoda) wybrano konfigurację o najwyższej wartości `val_accuracy` w fazie przeszukiwania, a następnie dotrenowano ją przez 20 epok. Wynik testowy uzyskany po tym etapie traktujemy jako końcową ocenę danej metody.

Tabela 3 oraz rysunek Rysunek 7 przedstawiają końcową wartość `test_accuracy` po 20-epokowym dotrenowaniu najlepszej konfiguracji każdej metody.

Metoda	CIFAR-10	CIFAR-100	FashionMNIST
ACO	0.8475	0.5031	0.9354
GA	0.8472	0.5587	0.9330
Harmony Search	0.8415	0.5181	0.9314
Manual search	0.8482	0.4666	0.9383
PSO	0.7373	0.4761	0.9146
Random search	0.8526	0.3879	0.9379

Tabela 3: Końcowa test_accuracy po 20-epokowym dotrenowaniu najlepszej konfiguracji.




Rysunek 7: Końcowa test_accuracy po retrainingu — metoda × zbiór.

W przeprowadzonym eksperymencie liderzy różnili się między zbiorami danych: random search uzyskał najwyższą końcową test_accuracy na CIFAR-10 (0.8526), GA zwyciężył na CIFAR-100 (0.5587), a manual search na FashionMNIST (0.9383). Na CIFAR-10 manual search był bardzo blisko random search (0.8482 wobec 0.8526), a ACO i GA również pozostawały w wąskim zakresie 0.847-0.848.

Manual search pozostaje jednak silną linią bazową. Na CIFAR-10 osiąga drugi wynik po random search, na CIFAR-100 wyprzedza tylko random search, a na FashionMNIST jest najlepszą metodą. Wskazuje to, że przy małym budżecie ewaluacji ręcznie dobrane konfiguracje mogą być bardzo konkurencyjne na prostszych zbiorach, ale na trudniejszych benchmarkach ustępują silniejszym heurystykom.

Krzywe dotrenowania na rysunku Rysunek 8 pozwalają ocenić, czy konfiguracje wybrane po krótkim treningu zachowują przewagę również w dłuższym uczeniu. Na CIFAR-10 wartości czołowych metod po dotrenowaniu są bardzo zbliżone, ale ranking zmienia się względem fazy przeszukiwania: w fazie search najlepszy był Harmony Search, natomiast po dotrenowaniu najwyższy wynik testowy uzyskał random search, a manual search był drugi. Szczególnie widoczny jest przypadek random search na CIFAR-100: konfiguracja miała wysoką jakość w fazie krótkiego przeszukiwania, ale po ponownym 20-epokowym treningu uzyskała najniższą końcową test_accuracy. Pokazuje to, że krótka ewaluacja jest użytecznym, ale niedoskonałym kryterium wyboru konfiguracji. Na FashionMNIST manual search pozostaje najlepszy, co pokazuje, że 10-epokowa ewaluacja była użytecznym, choć przybliżonym, kryterium wyboru konfiguracji do dalszego treningu.



Rysunek 8: Krzywe val_accuracy w trakcie 20-epokowego dotrenowania.

3.6. Zmienność jakości ocenianych konfiguracji

Dotychczasowe zestawienia koncentrowały się głównie na najlepszych konfiguracjach znalezionych przez poszczególne metody. Dodatkowo przeanalizowano rozkład jakości wszystkich konfiguracji ocenionych w fazie przeszukiwania. Tabela 4 pokazuje średnią oraz odchylenie standardowe val_accuracy i test_accuracy dla każdej metody na trzech zbiorach danych.

Wartości odchylenia standardowego nie opisują tutaj powtarzalności metod między niezależnymi uruchomieniami. Pokazują jedynie, jak bardzo różniły się wyniki konfiguracji ocenionych w ramach jednego przebiegu eksperymentu.

Metoda	C10 val	C10 test	C100 val	C100 test	FMNIST val	FMNIST test
ACO	0.6470 ± 0.1821	0.6432 ± 0.1814	0.2656 ± 0.1501	0.2655 ± 0.1514	0.8983 ± 0.1171	0.8932 ± 0.1169
GA	0.7554 ± 0.0874	0.7539 ± 0.0853	0.3701 ± 0.1282	0.3725 ± 0.1297	0.9283 ± 0.0099	0.9235 ± 0.0098
Harmony S.	0.6658 ± 0.1792	0.6646 ± 0.1788	0.3115 ± 0.1214	0.3105 ± 0.1231	0.9053 ± 0.1180	0.9005 ± 0.1174
Manual	0.7608 ± 0.0446	0.7583 ± 0.0429	0.3246 ± 0.0964	0.3227 ± 0.1022	0.9316 ± 0.0033	0.9246 ± 0.0023
PSO	0.5903 ± 0.2515	0.5889 ± 0.2526	0.2821 ± 0.1923	0.2819 ± 0.1934	0.8867 ± 0.1218	0.8825 ± 0.1213
Random	0.5960 ± 0.1977	0.5958 ± 0.1973	0.2202 ± 0.1359	0.2209 ± 0.1371	0.9016 ± 0.0368	0.8962 ± 0.0365

Tabela 4: Średnia i odchylenie standardowe jakości konfiguracji ocenionych w fazie przeszukiwania. Skróty: C10 — CIFAR-10, C100 — CIFAR-100, FMNIST — FashionMNIST.

3.7. Najlepsze konfiguracje

Tabela 5 zestawia najlepsze konfiguracje znalezione przez poszczególne metody na trzech zbiorach danych. Za najlepszą konfigurację uznano tę, która w fazie przeszukiwania uzyskała najwyższą wartość val_accuracy dla danej pary (zbiór danych, metoda). W tabeli pokazano najważniejsze hiperparametry wpływające na architekturę i trening; pełne konfiguracje, obejmujące wszystkie parametry z przestrzeni przeszukiwań, udostępniono w repozytorium projektu jako pliki report/results/tables/best_configs_*.csv [4].

Zbiór	Metoda	search val	search test	lr	bs	blocks	dropout	dense
CIFAR-10	ACO	0.8140	0.8137	1.0×10^{-3}	32	3	0.40	256
CIFAR-10	GA	0.8284	0.8221	1.85×10^{-4}	64	3	0.23	128
CIFAR-10	Manual	0.7980	0.7947	2.0×10^{-4}	128	3	0.40	256
CIFAR-10	PSO	0.7984	0.7834	1.0×10^{-2}	128	2	0.34	256
CIFAR-10	HS	0.8296	0.8278	1.43×10^{-3}	32	3	0.15	256
CIFAR-10	Random	0.8168	0.8064	5.35×10^{-4}	32	3	0.36	128
CIFAR-100	GA	0.5022	0.5051	1.85×10^{-4}	64	3	0.27	256
CIFAR-100	Manual	0.4288	0.4328	5.0×10^{-4}	128	2	0.30	256
CIFAR-100	Random	0.4990	0.5075	3.05×10^{-3}	64	2	0.10	256
CIFAR-100	HS	0.4656	0.4761	1.56×10^{-4}	32	3	0.12	128
CIFAR-100	ACO	0.4880	0.4876	1.0×10^{-3}	32	2	0.00	256
CIFAR-100	PSO	0.4816	0.4718	1.0×10^{-4}	32	2	0.00	256
FashionMNIST	Manual	0.9365	0.9251	2.0×10^{-4}	128	3	0.40	256
FashionMNIST	HS	0.9383	0.9318	8.30×10^{-4}	64	2	0.03	256
FashionMNIST	Random	0.9388	0.9278	1.43×10^{-3}	32	3	0.36	128
FashionMNIST	GA	0.9390	0.9327	1.52×10^{-3}	32	2	0.17	256
FashionMNIST	ACO	0.9383	0.9333	1.0×10^{-3}	32	2	0.25	256
FashionMNIST	PSO	0.9198	0.9148	9.78×10^{-3}	256	1	0.49	256

Tabela 5: Najlepsze konfiguracje znalezione przez metody na trzech zbiorach danych.

Warto zauważyć, że najlepsze konfiguracje nie tworzą jednego uniwersalnego wzorca dla wszystkich zbiorów. Na CIFAR-10 i CIFAR-100 najlepsze konfiguracje mają zazwyczaj 2-3 bloki, dropout od 0.00 do 0.40 oraz dense_units równe 128 lub 256, ale szczegóły architektury różnią się między metodami. Na FashionMNIST obraz jest bardziej zróżnicowany: część metod wybiera konfiguracje z 3 blokami i wyższym dropoutem, inne zatrzymują się przy 1-2 blokach i niższym dropoutem. Oznacza to, że skuteczność konfiguracji zależy zarówno od zbioru danych, jak i od sposobu eksploracji przestrzeni przez daną metodę.

4. Dyskusja i wnioski

W przeprowadzonym eksperymencie liderzy różnili się między zbiorami danych: random search uzyskał najwyższą końcową test_accuracy na CIFAR-10, GA zwyciężył na CIFAR-100, a manual search na FashionMNIST. Wynik ten sugeruje, że w badanej przestrzeni hiperparametrów nie ma jednej metody dominującej na wszystkich zbiorach, a skuteczność zależy od charakterystyki zbioru i budżetu ewaluacji.

Istotnym wynikiem jest również bardzo dobra pozycja manual search. Ręcznie dobrane konfiguracje okazały się szczególnie konkurencyjne na FashionMNIST, gdzie po dotrenowaniu uzyskały najlepszy wynik, oraz na CIFAR-10, gdzie były bardzo blisko zwycięzcy. Na CIFAR-100 manual search wyprzedza tylko random search. Pokazuje to, że przy małym budżecie kilka sensownie dobranych konfiguracji eksperckich może być trudną do pobicia linią bazową.

PSO było jedną ze słabszych metod, szczególnie na CIFAR-10 i FashionMNIST. Możliwym wyjaśnieniem jest niedopasowanie klasycznej, ciągłej reprezentacji PSO do mieszanej przestrzeni hiperparametrów, w której wiele wymiarów ma charakter dyskretny lub kategoriowy. Wartości cząstek musiały być naprawiane przez zaokrąglanie lub mapowanie do najbliższych dopuszczalnych wartości, co mogło ograniczać użyteczność mechanizmu prędkości.

Harmony Search osiągał wyniki pośrednie. Po 20-epokowym dotrenowaniu na CIFAR-100 był drugą najlepszą metodą, ale na CIFAR-10 i FashionMNIST ustępował odpowiednio random search oraz manual search. Jedną z możliwych przyczyn jest wysoka wartość parametru HMCR, która sprzyja wybieraniu wartości z pamięci harmonii. Przy małej pamięci i ograniczonym budżecie może to prowadzić do zbyt szybkiej eksploatacji wcześniej znalezionych konfiguracji kosztem dalszej eksploracji.

Wyniki po 20-epokowym dotrenowaniu wskazują, że krótka, 10-epokowa ewaluacja była użytecznym, ale niedoskonałym kryterium wyboru konfiguracji do dalszego treningu. Przypadek random search

na CIFAR-100 pokazuje, że wysoki wynik po krótkim treningu nie zawsze przekłada się na stabilny wynik po ponownym, dłuższym treningu.

4.1. Ograniczenia i możliwe dalsze analizy

Najważniejszym ograniczeniem eksperymentu jest użycie pojedynczego ziarna losowego. Wyniki metod stochastycznych mogą zależeć od inicjalizacji populacji, losowania konfiguracji, podziału train/validation oraz inicjalizacji wag sieci. Silniejsze wnioski wymagałyby powtórzenia eksperymentów dla kilku seedów i raportowania średnich oraz odchyleń standardowych wyników końcowych.

Drugim ograniczeniem jest mały budżet przeszukiwania. Pięćdziesiąt ewaluacji to realistyczny, ale nadal ograniczony budżet dla 12-wymiarowej przestrzeni hiperparametrów.

Trzecim jest brak studium hiperparametrów algorytmów. Nie przeanalizowano, jak różne ustawienia parametrów metaheurystyk (np. rozmiar populacji, prawdopodobieństwo mutacji, parametry PSO) wpływają na jakość znalezionych konfiguracji. Dalsze analizy mogłyby zbadać tę kwestię.

Bibliografia

- [1] Q. S. Hamad, H. Samma, i S. A. Suandi, „Optimization of Convolutional Neural Network Hyperparameter for Medical Image Diagnosis using Metaheuristic Algorithms: A short Recent Review (2019-2022)”. [Online]. Dostępne na: <https://arxiv.org/abs/2412.17956>
- [2] H. Xiao, K. Rasul, i R. Vollgraf, „Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms”.
- [3] A. Krizhevsky, V. Nair, i G. Hinton, „Learning multiple layers of features from tiny images”, technical report, 2009. [Online]. Dostępne na: <https://www.cs.toronto.edu/~kriz/cifar.html>
- [4] J. Grześ i T. Smyda, „cnn-metaheuristics: Metaheuristic Hyperparameter Tuning for CNNs”. [Online]. Dostępne na: <https://github.com/tsmyda/cnn-metaheuristics>